



Aplicação de Machine Learning para detecção de ameaças em dispositivos de Internet das Coisas

Alessandra Carolina Domiciano

Ana Paula Serafim de Góis

A glowing green padlock is centered on the left side of the slide. It is set against a dark blue background with a complex, glowing circuit board pattern. The padlock itself is a vibrant green with a textured, almost pixelated appearance, suggesting digital security or encryption.

Introdução

- A análise de tráfego de rede baseada em Machine Learning (ML) é uma alternativa para a detecção de ameaças de IoT.
- Essa abordagem oferece maior flexibilidade na identificação de ataques cibernéticos e suas variações, além de permitir otimizações para operação com baixa sobrecarga computacional.
- Os modelos de ML devem ser leves e rápidos, com boa capacidade de generalização e desempenho equilibrado, com um bom compromisso entre sensibilidade e especificidade.

Introdução

- Este trabalho se baseia no modelo proposto em [3], e **seu objetivo é construir um ambiente de teste para avaliação da proposta.**
- Para tanto, foi implementada uma rede IoT com dispositivos físicos e um sistema de teste do modelo executado em uma Raspberry Pi 4. A rede é capaz de produzir tráfego benigno (MQTT) e maligno (Scan A, Scan sU e Sparta).
- Observaram-se os resultados das métricas de classificação binária, priorizando F1 score e latência de predição.





Metodologia

O desenvolvimento deste trabalho pode ser dividido em três etapas:

1. Provisionamento da rede IoT.
2. Desenvolvimento do sistema de teste.
3. Retreinamento do modelo.

Metodologia

Provisionamento da rede IoT:




Metodologia

Provisionamento da rede IoT:

- **Raspberry Pi Zero W:** executa um broker MQTT.
- **ESP32:** executa um cliente MQTT que publica dados em um tópico de teste e assina esse mesmo tópico.
- **Raspberry Pi 4 (vítima):** executa um cliente MQTT que publica dados em um tópico de teste e assina esse mesmo tópico. **É quem executa o sistema de testes.**
- **Raspberry Pi 3 (atacante):** dispara os ataques contra a vítima.

Metodologia

Sistema de teste:



Metodologia

Sistema de teste:

1. O sistema inicia realizando a captura do tráfego de rede que entra e sai da interface do dispositivo vítima;
2. Prossegue fazendo o processamento dos dados, que se trata da extração dos atributos. São extraídos 30 atributos, que consistem em campos de cabeçalho dos protocolos IP, TCP ou UDP e MQTT.
3. Esse processo é realizado pacote a pacote até que o usuário pare a captura.
4. Uma vez que isso ocorre, o conjunto de dados é submetido a um novo processamento, desta vez, para ajustar os valores dos atributos e selecioná-los conforme o metadata utilizado no treinamento do modelo.
5. Por fim, os dados são entregues ao modelo, que é integrado ao sistema, para realizar as previsões e gerar as métricas de avaliação.

Metodologia

Retreinamento do modelo:

Dataset
MQTT-IoT-
IDS2020

Dados gerados a partir de uma rede simulada:

- Tráfego normal: 10,35%
- Scan A: 0,18%
- Scan sU: 0,1%
- Sparta: 89,36%

Pré-processamento
e pipeline HPO

Amostragem do dataset

Seleção de atributos

Filtragem de amostras

HPO para melhor latência,
melhor F1-score e melhor
equilíbrio entre ambos

Algoritmo
XGBoost


Baseado em árvores de
decisão

Empregado tanto para
regressão quanto para
classificação


Combina diversos modelos
fracos para formar um
modelo forte (ensemble)

Resultados e discussão

- O experimento consistiu em enviar tráfego de rede benigno e maligno ao dispositivo vítima, a fim de verificar o desempenho do modelo em um cenário real e diferente daquele que gerou os dados de treinamento.
- Ao todo, durou em torno de 1h e foram classificados 26520 pacotes, com a distribuição ao lado.
- Buscou-se produzir um equilíbrio entre as classes e entre os ataques. Para tanto, os ataques Sparta, Scan A e Scan sU foram executados uma, duas e duas vezes, respectivamente, enquanto o tráfego MQTT fluía continuamente.



Resultados e discussão



Resultados e discussão


De maneira geral, os quatro modelos com melhor desempenho apresentaram resultados semelhantes, com pequenas variações.

	Precisão	Recall	F1 score	Acurácia
xgb_full	78,0%	65,7%	61,7%	66,0%
xgb_sampled	72,9%,	62,9%	58,5%	63,2%
xgb_reduced	78,1%	60,6%	53,5%	60,9%
xgb_filtred	78,8%	62,5%	56,5%	62,8%

Esses valores representam métricas médias e, portanto, não refletem as diferenças de desempenho entre as classes.

Optou-se por analisar mais detalhadamente o desempenho do modelo **xgb_full**, pois ele alcançou o maior F1-score.

Resultados e discussão




Resultados e discussão

- A análise dos resultados revela um **desempenho significativamente desequilibrado entre as classes**, com favorecimento da **classe benigna**.
- Isso é evidenciado pelo elevado recall (98,7%), indicando que quase todas as amostras benignas foram corretamente classificadas.
- No entanto, a precisão associada a essa classe é relativamente baixa (59,9%), sugerindo que o modelo produz um número considerável de falsos positivos.
- O desequilíbrio entre precisão e recall resulta em um F1-score de 74,6% para a classe benigna, o que, embora possa ser considerado razoável, mascara a fragilidade do modelo em relação à outra classe.

Resultados e discussão

- Já o desempenho para a **classe maligna** é bastante insatisfatório. Embora a precisão seja elevada (96,2%), o recall é extremamente baixo (32,7%).
- Isso indica que o modelo erra ao classificar mais de dois terços das amostras de ataques, o que implica uma alta taxa de falsos negativos.
- O F1-score para essa classe é de 48,8%, refletindo um desempenho baixo.
- As taxas de acertos e erros para cada classe podem ser melhor compreendidas observando a matriz de confusão.


Resultados e discussão



Resultados e discussão

- Para uma análise ainda mais aprofundada, os dados de classificação gerados pelo modelo `xgb_full` foram armazenados em arquivo para permitir uma análise posterior do desempenho por tipo de ataque.
- Para isso, os dados foram segmentados em três subconjuntos, cada um contendo amostras de um único ataque específico, juntamente com tráfego benigno.
- A proporção entre classes em cada subconjunto foi mantida equilibrada, com cerca de 50% de amostras benignas.

Resultados e discussão




Resultados e discussão

Observa-se que o modelo apresenta um desempenho razoável nos testes com os ataques isolados Scan A e Scan U e um desempenho significativamente inferior para o ataque isolado Sparta.

	Precisão	Recall	F1 score	Acurácia
Scan A	82,1%	73,2%	71,4%	73,5%
Scan U	81,4%,	74,9%	73,6%	75,1%
Sparta	25,2%	49,7%	33,4%	50,1%

É importante salientar que tais métricas representam valores médios agregados, os quais podem ocultar desequilíbrios significativos no desempenho entre as classes benigna e maligna, conforme discutido na análise geral do modelo.

Resultados e discussão



Conclusão

- Foi criado um cenário realista e funcional para a execução de testes de detecção de ameaças cibernéticas em ambientes IoT, demonstrando a viabilidade de aplicação local de modelos de machine learning para tal finalidade.
- No entanto, os resultados evidenciam que o sistema desenvolvido ainda demanda melhorias significativas, sobretudo em relação à sua capacidade de identificar com precisão os ataques, devido a alta taxa de falsos positivos.
- Como trabalho futuro, propõe-se a integração dos processos de captura e pré-processamento de pacotes ao fluxo de predição, com o intuito de incluir essas etapas ao cálculo de latência média por amostra, o uso de outros bancos de dados e ameaças de IoT e a utilização de outros tipos de modelos, como os de IA generativa.



Obrigada!

Alessandra Carolina Domiciano

Ana Paula Serafim de Góis